基于多元时间序列的自适应贪婪高斯分段算法

摘　要：现有多元时间序列分段算法中分段点的选择以及分段个数的确定往往需要分别独立完成，大大增加了算法的计算复杂度．为解决上述问题，本文提出一种基于多元时间序列的自适应贪婪高斯分段算法．该算法将多元时间序列各个分段所对应的数据解释为来自不同多元高斯分布的独立样本，进而将分段问题转化为协方差正则化的最大似然估计问题进行求解．为提高学习效率，采用贪婪搜寻方法使每个段的似然值最大化进而近似地找到最优段点，并且在搜寻的过程中利用信息增益方法自适应地获取最优的分段个数，避免分段个数确定和分段点选择分别独立进行，从而减少了计算的复杂度.实验结果表明，本文提出的方法在不同数据集上都得到了有效验证.

关键词：多元时间序列；高斯分段模型；信息增益；自适应；

中图分类号：TP273　　**文献标志码：**A

DOI:（编辑给出）　　**开放科学（资源服务）标识码（OSID）:**

Adaptive greedy gaussian segmentation algorithm based on multivariate time series

Abstract：For most multivariate time series segmentation algorithms, the selection of segmentation points and the determination of the number of segments often need to be completed independently, which greatly increase the computational complexity of the algorithm. In order to solve the above problems, an adaptive greedy Gaussian segmentation algorithm based on multivariate time series is proposed in this paper. The algorithm interprets the data on the segmentation of multivariate time series as independent samples from different multivariate Gaussian distributions, and then transforms the segmentation problem into a covariance-regularized likelihood maximization problem for solving. In order to improve the learning efficiency, the greedy search method is adopted to maximize the likelihood value of each segment to find the optimal segment point approximately. During the searching process, the information gain method is adopted to adaptively obtain the optimal number of segments, which avoids from realizing the determination of the number of segments and the selection of segment points independently to reduce the computational complexity. Experimental results show that our algorithm has been effectively verified on different data sets . □□□

Key words：Multivariate time series; segmented Gaussian model; Information gain; Adaptive;

0 引　言

近年来，随着传感器技术的不断发展，许多应用领域(例如环境监测、便携式穿戴设备等)对于时间序列数据的收集量呈现出指数级的增长．作为一种重要的时间序列预处理方法，时间序列分段技术能够根据时序数据的某些特性将其分割为一系列离散的、非重叠的子序列，进而提供更加紧凑的表示来提取数据中感兴趣的模式，以实现进一步的知识挖掘，如分类、聚类以及规则挖掘等[1-4]．早期的时间序列分段研究主要专注于对一元时间序列分段，采用的方法包括分段线性表示(Piecewise Linear Representation, PLR)[5]，分支定界(AUG)[6] 以及遗传算法(Genetic Algorithm, GA)[7-9]等．这些分段方法对于一元时间序列能够取得良好的分段效果．然而，在实际应用场景中，拥有更高数据维度的多元时间序列能够提供比一元时间序列更为丰富的信息量，并且多元时间序列所属多个变量的关联关系变化情况复杂，这将致使一元时间序列分段算法应用效果不理想．因此，针对多元时间序列设计稳定且高效的分段算法具有重大意义．

目前，针对多元时间序列的分段算法大都包含以下三个部分[19]：1) 成本函数 2) 搜索(优化)方法 3) 对于分段点个数的确定机制．其中,文献[10] 提出一种称为 SMTS-DP 的分段方法，该方法将 Hubert 分段成本[20]作为成本函数，采用动态规划作为优化方法进行分段位置搜索，并利用贝叶斯信息准则[12]（BIC）确定最优分段点的个数．SMTS-DP 在水文多元时间序列数据集上能够取得较好的分段效果．文献[11] 在文献[10] 的基础上

收稿日期：－年－月－日；**录用日期：**－年－月－日．

通讯作者．　E-mail: □□□□.

加以改进，提出了基于动态因子模型的分段算法(SMTS-FD). 该算法首先利用聚类方法将多元时间序列中相似的变量进行聚类，然后利用动态因子模型对变量降维，该步骤能够在一定程度上提高算法的运行效率. 文献[14] 提出一种基于 KPCA 和 G-G 模糊聚类的分段算法 FSTS-KPG. 该算法首先利用 KPCA 对多元时间序列降维，根据 AP 方法获取最大分段数目，再基于改进的 G-G 模糊聚类进行分段，并根据改进的 DBI 指数确定最佳分段数. FSTS-KPG 方法在气象多元时间序列数据集上取得了良好的分段效果.但上述方法对于分段点位置的确定以及最优分段数目的选择是两个独立进行的步骤，这增加了算法的复杂性. 为此,文献[15]提出一种称为 IGTS 的分段算法，它采用了基于熵的成本函数,同样利用动态规划对分段点位置进行寻优并同步确定最优分段数. 上述方法都采用动态规划或模糊聚类对所有可能的分段点组合进行搜索，虽然能够获得全局最优解，但由于搜索空间的扩大将导致分段效率大幅下降. 针对上述问题，文献[13] 提出了一种分段算法 GGS，其将多元时间序列各个分段所对应的数据解释为来自不同多元高斯分布的独立样本，采用对数似然函数作为成本函数，进而将分段问题转化为协方差正则化的最大似然估计问题求解. GGS 能够取得良好的分段结果，但是该算法在使用前必须进行交叉验证以获得合适的分段数，这使得分段位置确定和分段数选择两个步骤相互孤立.

为了提高多元时间序列的分段效率，并且在分段点选择的同时获取最佳的分段数目，本文在文献[13]的基础上提出了一种基于多元时间序列的自适应贪婪高斯分段算法(adaptive greedy Gaussian segmentation of multivariate time series, AGGS-MTS). 该算法在贪婪搜寻分段点的过程中引入信息增益(information gain)，自适应地获取最优的分段个数，从而避免了分段点位置确定和分段数目选择的孤立问题，较大程度上提升了算法的运行效率，实现计算复杂性和分段准确性的平衡.

1 问题定义

令原始的多元时间序列数据矩阵表示为 $\mathbf{S}=\{\mathbf{x}_1,...,\mathbf{x}_t,...,\mathbf{x}_n\}$，如公式(1)所示，其中 $\mathbf{x}_t\in\mathbb{R}^m$，$n$ 代表时间序列的长度，$x_{jt}(j=1,2,...,m)$ 是第 j 个变量在时刻 t 的采样值.

$$\mathbf{S}=\begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1t} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2t} & \cdots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ x_{j1} & x_{j2} & \cdots & x_{jt} & \cdots & x_{jn} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{mt} & \cdots & x_{mn} \end{bmatrix} \tag{1}$$

假设多元时间序列 $\mathbf{S}$ 能够划分为 $k+1$ 个区间段 $[b_0,b_1),[b_1,b_2),...,[b_{r-1},b_r),...,[b_{k-1},b_k),[b_k,b_{k+1}]$ $(b_0=1, b_{k+1}=n)$，分段点集合为 $\{b_0,b_1,\cdots b_r,\cdots,b_k,b_{k+1}\}$. 本文的目标是从多元时间序列数据中找到最佳的分段个数以及分段位置. 表 1 为文中涉及的符号及含义.

表 1 符号及含义

符号	含义
$\mathbf{S}$	多元时间序列，$\mathbf{S}\in\mathbb{R}^{m\times n}$
$\mathbf{x}_t$	多元时间序列在时刻 t 的采样值，$\mathbf{x}_t\in\mathbb{R}^m$
x_{jt}	第 j $(j=1,...,m)$ 个时间序列在时刻 t 的采样值
b	分段点集合 $b=\{b_0,b_1...,b_r,...,b_k,b_{k+1}\}$
k	分段点个数
$\mathbf{S}_r$	$\mathbf{S}$ 的第 r 个分段，表示为 $[b_{r-1},b_r)$
$\boldsymbol{\mu}^{(r)}$	第 r 个分段的均值向量
$\boldsymbol{\Sigma}^{(r)}$	第 r 个分段的协方差矩阵
l_k	时间序列分成 k 段时信息增益损失函数值
ρ_k	时间序列分成 k 段时信息增益损失值变化率
$H(\mathbf{S})$	整个时间序列的信息增益
$H(\mathbf{S}_r)$	第 r 段的信息增益

2 基于多元时间序列的自适应贪婪高斯分段算法(AGGS-MTS)

2.1 高斯分段模型

令 $\mathbf{S}_r$ 代表 $\mathbf{S}=\{\mathbf{x}_1,\mathbf{x}_2,...,\mathbf{x}_t,...,\mathbf{x}_n\}$ 中第 r 个分段 $[b_{r-1},b_r)$，$\mathbf{S}_r=<\mathbf{x}_{b_{r-1}},...,\mathbf{x}_{b_r-1}>$.第 r 个分段中每一个观测点 x_t 都服从多元高斯分布，其均值向量是 $\boldsymbol{\mu}^{(r)}$，协方差矩阵是 $\boldsymbol{\Sigma}^{(r)}$，

$$\boldsymbol{\mu}^{(r)}=\frac{1}{b_r-b_{r-1}}\sum_{t=b_{r-1}}^{b_r-1}\mathbf{x}_t \tag{2}$$

$$\boldsymbol{\Sigma}^{(r)}=\frac{1}{b_r-b_{r-1}}\sum_{t=b_{r-1}}^{b_r-1}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})^T \tag{3}$$

上述基于多元高斯分布的模型称为高斯分段模型(segmented Gaussian model, SGM)，其可以将时间序列分段问题转化为高斯分段模型的参数求解问题，即选择合适的参数使得整个时间序列数据可以用多个独立的高斯模型来表示，如图 1 所

示.

图 1 高斯分段模型

为了学习高斯分段模型的相关参数，需要计算 $\mathbf{S}=\{\mathbf{x}_1,\mathbf{x}_2,\ldots,\mathbf{x}_t,\ldots,\mathbf{x}_n\}$ 的对数似然函数以进行最大似然估计．$\mathbf{S}=\{\mathbf{x}_1,\mathbf{x}_2,\ldots,\mathbf{x}_t,\ldots,\mathbf{x}_n\}$ 的对数似然函数表示如下，

$$\begin{aligned}L(b,\boldsymbol{\mu},\boldsymbol{\Sigma})&=\sum_{t=1}^{n}\left(-\frac{1}{2}(\mathbf{x}_t-\boldsymbol{\mu}_t)^T\boldsymbol{\Sigma}^{-1}(\mathbf{x}_t-\boldsymbol{\mu}_t)-\frac{1}{2}\log\det\boldsymbol{\Sigma}-\frac{m}{2}\log(2\pi)\right)\\&=\sum_{r=1}^{k+1}\sum_{t=b_{r-1}}^{b_r-1}\left(-\frac{1}{2}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})^T(\boldsymbol{\Sigma}^{(r)})^{-1}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})-\frac{1}{2}\log\det\boldsymbol{\Sigma}^{(r)}-\frac{m}{2}\log(2\pi)\right)\\&=\sum_{r=1}^{k+1}L^{(r)}(b_{r-1},b_r,\boldsymbol{\mu}^{(r)},\boldsymbol{\Sigma}^{(r)})\end{aligned}\tag{4}$$

其中，

$$\begin{aligned}&L^{(r)}(b_{r-1},b_r,\boldsymbol{\mu}^{(r)},\boldsymbol{\Sigma}^{(r)})\\&=\sum_{t=b_{r-1}}^{b_r-1}\left(-\frac{1}{2}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})^T(\boldsymbol{\Sigma}^{(r)})^{-1}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})-\frac{1}{2}\log\det\boldsymbol{\Sigma}^{(r)}-\frac{m}{2}\log(2\pi)\right)\\&=-\frac{1}{2}\sum_{t=b_{r-1}}^{b_r-1}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})^T(\boldsymbol{\Sigma}^{(r)})^{-1}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})-\frac{b_r-b_{r-1}}{2}(\log\det\boldsymbol{\Sigma}^{(r)}+m\log(2\pi))\end{aligned}\tag{5}$$

式(5)中的集合 b 为 $b=<b_0,b_1,\ldots,b_r,\ldots,b_k,b_{k+1}>$，$\boldsymbol{\mu}=<\boldsymbol{\mu}^{(1)},\ldots,\boldsymbol{\mu}^{(r)},\ldots,\boldsymbol{\mu}^{(k+1)}>$，$\boldsymbol{\Sigma}=<\boldsymbol{\Sigma}^{(1)},\ldots,\boldsymbol{\Sigma}^{(r)},\ldots,\boldsymbol{\Sigma}^{(k+1)}>$ 为高斯分段模型中的相关参数．在上述公式中，如果 $\boldsymbol{\Sigma}$ 不是正定的，则 $\log\det\boldsymbol{\Sigma}$ 定义为 $-\infty$，b_r-b_{r-1} 代表第 r 段的长度．为了避免一个片段中的变量个数多于时间序列观测点个数时出现错误[16]，在公式(5)中添加一个协方差正则化项，形式如下：

$$\begin{aligned}\varphi(b,\boldsymbol{\mu},\boldsymbol{\Sigma})&=L(b,\boldsymbol{\mu},\boldsymbol{\Sigma})-\lambda\sum_{r=1}^{k+1}Tr(\boldsymbol{\Sigma}^{(r)})^{-1}\\&=\sum_{r=1}^{k+1}\left(L^{(r)}(b_{r-1},b_r,\boldsymbol{\mu}^{(r)},\boldsymbol{\Sigma}^{(r)})-\lambda Tr(\boldsymbol{\Sigma}^{(r)})^{-1}\right)\end{aligned}\tag{6}$$

其中 $\lambda\geq 0$ 是一个正则化参数，$Tr(\boldsymbol{\Sigma}^{(r)})$ 是分段 r 所对应协方差矩阵的迹．一般认为协方差矩阵 $\boldsymbol{\Sigma}^{(r)}$ 是正定(可逆)的，但是在高维度协方差矩阵中往往不满足这一条件，因此在协方差矩阵中同样加入一个正则化项，则公式(3)变为如下形式：

$$\boldsymbol{\Sigma}^{(r)}=\frac{1}{b_r-b_{r-1}}\sum_{t=b_{r-1}}^{b_r-1}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})^T+\frac{\lambda}{b_r-b_{r-1}}I\tag{7}$$

为了书写方便，令

$$S^{(r)}=\frac{1}{b_r-b_{r-1}}\sum_{t=b_{r-1}}^{b_r-1}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})^T\tag{8}$$

将公式(2)、(7)和(8)带入公式(6)中，经过协方差正则化的对数似然函数可以进一步表示为：

$$\begin{aligned}\varphi(b,\boldsymbol{\mu},\boldsymbol{\Sigma})&=\sum_{r=1}^{k+1}\left(L^{(r)}(b_{r-1},b_r,\boldsymbol{\mu}^{(r)},\boldsymbol{\Sigma}^{(r)})-\lambda Tr(\boldsymbol{\Sigma}^{(r)})^{-1}\right)\\&=\sum_{r=1}^{k+1}\left(-\frac{1}{2}\sum_{t=b_{r-1}}^{b_r-1}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})^T(\boldsymbol{\Sigma}^{(r)})^{-1}(\mathbf{x}_t-\boldsymbol{\mu}^{(r)})-\frac{b_r-b_{r-1}}{2}(\log\det(S^{(r)}+\frac{\lambda}{b_r-b_{r-1}}I)+m\log(2\pi))\right.\\&\quad\left.-\lambda Tr(S^{(r)}+\frac{\lambda}{b_r-b_{r-1}}I)^{-1}\right)\\&=C+\sum_{r=1}^{k+1}\psi(b_{r-1},b_r)\end{aligned}\tag{9}$$

其中 $C=-(mn/2)(\log(2\pi)+1)$ 是一个常量，

$$\psi(b_{r-1},b_r)=-\frac{1}{2}\left((b_r-b_{r-1})\log\det(S^{(r)}+\frac{\lambda}{b_r-b_{r-1}}I)+\lambda Tr(S^{(r)}+\frac{\lambda}{b_r-b_{r-1}}I)^{-1}\right)\tag{10}$$

为第 r 个分段的对数似然函数值．最终高斯分段模型用于最大似然估计的对数似然函数如公式(9)所示．

2.2 自适应贪婪高斯分段模型

为了实现多元时间序列分段，最优分段数目的确定是较为重要的一环．倘若确定的分段数过小，将致使分段算法仅仅捕捉到显著变化，无法充分揭示多元时间序列的演变过程，反之，将过度关注微小变化趋势甚至噪声，产生过拟合问题[19]．文献[13]所提出的基于高斯分段模型的算法需要提前采取交叉验证以确定分段数，而由此指定的分段数通常并不准确，并且交叉验证使得分段位置确定和分段数选择相互孤立．为解决上述问题，本文提出了基于多元时间序列的自适应贪婪高斯分段算法(AGGS-MTS)．该算法在采用贪婪搜索分段点位置的过程中同时引入信息增益，可

自适应地确定最优分段数目,避免分段位置确定和分段数选择相互独立，进而大大提升算法的分段效率.

通过计算高斯分段模型的协方差正则化对数似然函数(9)，AGGS-MTS 采取贪婪搜索的方式，循环遍历每个时间点，找到使整体对数似然函数值取最大值的点作为新的分段点，每次循环自上而下的增加一个分段点.下面详细说明 AGGS-MTS 的具体运行过程.

在寻找第一个分段点的过程中($k=1$)，算法首先初始化 $b_0=0, b_2=n$，然后进行贪婪搜寻，遍历多元时间序列 $\mathbf{S}$ 每一个时刻 t ($t\in[b_0,b_2)$)，并根据公式(10)计算时刻 t 所对应的 $\psi(b_0,t)+\psi(t,b_2)$ 的值，

$$\psi(b_0,t)+\psi(t,b_2)=-\frac{1}{2}\left((t-b_0)\log\det(S^{(1)}+\frac{\lambda}{t-b_0}I)-\lambda Tr(S^{(1)}+\frac{\lambda}{t-b_0}I)^{-1}\right)-\frac{1}{2}\left((b_2-t)\log\det(S^{(2)}+\frac{\lambda}{b_2-t}I)-\lambda Tr(S^{(2)}+\frac{\lambda}{b_2-t}I)^{-1}\right) \tag{11}$$

如果某一时刻 t 使得 $\psi(b_0,t)+\psi(t,b_2)$ 在所有情况中取最大值，则认定时刻 t 为本次循环的最佳分段点，将该点加入分段点集合，并且更新该点的标号为 b_1，这样便得到了将整个时间序列分为两段的段点集合 $\{b_0,b_1,b_2\}$.

搜寻第二个分段点 ($k=2$) 的过程和上述过程类似. 首先在第一个分段区间 $[b_0,b_1)$ 中进行贪婪搜寻，找到某一时刻 t 使得 $\psi(b_0,t)+\psi(t,b_1)$ 最大，

$$\psi(b_0,t)+\psi(t,b_1)=-\frac{1}{2}\left((t-b_0)\log\det(S^{(1)}+\frac{\lambda}{t-b_0}I)-\lambda Tr(S^{(1)}+\frac{\lambda}{t-b_0}I)^{-1}\right)-\frac{1}{2}\left((b_1-t)\log\det(S^{(2)}+\frac{\lambda}{b_1-t}I)-\lambda Tr(S^{(2)}+\frac{\lambda}{b_1-t}I)^{-1}\right) \tag{12}$$

将该时刻 t 作为预选分段点保存.

然后，在第二个分段区间 $[b_1,b_2)$ 进行贪婪搜寻，找到一个时刻 t' 使得 $\psi(b_1,t')+\psi(t',b_2)$ 最大，

$$\psi(b_1,t')+\psi(t',b_2)=-\frac{1}{2}\left((t'-b_1)\log\det(S^{(1)}+\frac{\lambda}{t'-b_1}I)-\lambda Tr(S^{(1)}+\frac{\lambda}{t'-b_1}I)^{-1}\right)-\frac{1}{2}\left((b_2-t')\log\det(S^{(2)}+\frac{\lambda}{b_2-t'}I)-\lambda Tr(S^{(2)}+\frac{\lambda}{b_2-t'}I)^{-1}\right) \tag{13}$$

将该时刻 t' 作为另一个预选分段点并保存.

当完成所有区间的贪婪搜寻后，比较 $\psi(b_0,t)+\psi(t,b_1)+\psi(b_1,b_2)$ 以及 $\psi(b_0,b_1)+\psi(b_1,t')+\psi(t',b_2)$ 的大小，然后选择结果大的预选段点作为真正的分段点，将新的段点加入分段点集合，按照时间次序更新所有分段点标号，进而得到整个时间序列的分段点集合 $\{b_0,b_1,b_2,b_3\}$.

以此类推，在贪婪搜寻每个分段区间并添加候选分段点时，需要遵循使目标函数(14)最大化的原则完成该步骤.

$$\max-\frac{1}{2}\sum_{r=1}^{k+1}\left((b_r-b_{r-1})\log\det(S^{(r)}+\frac{\lambda}{b_r-b_{r-1}}I)-\lambda Tr(S^{(r)}+\frac{\lambda}{b_r-b_{r-1}}I)^{-1}\right) \tag{14}$$

为实现在搜寻分段点位置的同时对分段数进行自适应确定，AGGS-MTS 在每次确定增加一个分段点后，计算增加分段点前后信息增益损失值的变化. 例如，当分段点个数由 1 增加到 2 之后计算其分段前后的信息增益损失值变化率，

$$\rho_1=\frac{l_1-l_0}{l_2-l_1} \tag{15}$$

其中 l_0 为时间序列未分段前的信息增益损失值，其值为 0，l_1 为获得第一个分段点后时间序列被分成两段时的信息增益损失值，

$$l_1=H(\mathbf{S})-\sum_{r=1}^{2}\frac{|\mathbf{s}_r|}{|\mathbf{S}|}H(\mathbf{s}_r) \tag{16}$$

其中 $|\mathbf{s}_r|=b_r-b_{r-1}$ 为第 r 段的长度，$H(\mathbf{S})$ 为整个时间序列未被分段的信息增益，

$$H(\mathbf{S})=-\sum_{j=1}^{m}p_j\log p_j \tag{17}$$

$$p_j=\frac{\sum_{t=1}^{n}x_{jt}}{\sum_{j=1}^{m}\sum_{t=1}^{n}x_{jt}} \tag{18}$$

其中 $\sum_{t=1}^{n}x_{jt}$ 表示多元时间序列中第 j 个时间序列所有观测点的和，$\sum_{j=1}^{m}\sum_{t=1}^{n}x_{jt}$ 表示多元时间序列中所有时间序列所有观测点的和，$H(\mathbf{s}_r)$ 为第 r 段的信息增益，

$$H(\mathbf{s}_r)=-\sum_{j=1}^{m}p_{rj}\log p_{rj} \tag{19}$$

$$p_{rj}=\frac{\sum_{t=b_{r-1}}^{b_r-1}x_{jt}}{\sum_{j=1}^{m}\sum_{t=b_{r-1}}^{b_r}x_{jt}} \tag{20}$$

l_2 为获得第二个分段点后时间序列被分成三段时的信息增益损失值,

$$l_2=H(\mathbf{S})-\sum_{r=1}^{3}\frac{|\mathbf{s}_r|}{|\mathbf{S}|}H(\mathbf{s}_r) \tag{21}$$

同理, 当分段点个数为 3 时, 其分段前后的信息增益损失值变化率为,

$$\rho_2=\frac{l_2-l_1}{l_3-l_2} \tag{22}$$

依次类推, 可以得到当分段点个数为 k 时的信息增益损失值 l_k 和信息增益损失值变化率 ρ_k,

$$l_k=H(\mathbf{S})-\sum_{r=1}^{k+1}\frac{|\mathbf{s}_r|}{|\mathbf{S}|}H(\mathbf{s}_r) \tag{23}$$

$$\rho_k=\frac{l_k-l_{k-1}}{l_{k+1}-l_k} \tag{24}$$

为了自适应确定最优分段点的个数, AGGS-MTS 算法使用信息增益损失值变化率作为评估指标. 当确定了 k 个分段点后便可以得到在分段过程中所有的信息增益损失值变化率集合 $\{\rho_1,\rho_2,...,\rho_k\}$, 最佳分段点的个数为拥有最大 ρ 所对应的 k 值, 因为当时间序列在该分段点个数时信息增益损失函数趋势的偏差急剧减小. 因此, 基于高斯分段模型的 AGGS-MTS 将贪婪搜寻与信息增益损失值变化率相结合, 可以快速的对多元时间序列进行分段, 同时获得最佳分段点的个数.

2.3 算法实现步骤

AGGS-MTS 能够有效的处理高维的多元时间序列, 并且在整个分段过程中, 引入信息增益损失函数的变化率来自适应确定最佳的分段个数. 算法的整体流程如图 2, 具体的实现过程如下:

输入: 多元时间序列 $\mathbf{S}=\{\mathbf{x}_1,\mathbf{x}_2,...,\mathbf{x}_t,...,\mathbf{x}_n\}$, 最大分段点个数[13] $k_{\max}=(n/m)/3$.

输出: 分段点集合 $b=\{b_0,b_1...,b_r,...,b_k,b_{k+1}\}$, 最佳分段点个数 k.

Step 1: 初始化 $b=\{b_0=0,b_2=n\}$, $\rho_{\max}=0$.

Step 2: 令 $k=1$, 遍历初始时间序列 $\mathbf{S}$, 找到时刻 t 使得 $\psi(b_0,t)+\psi(t,b_2)$ 最大, 令该点作为第一个分段点, 并加入分段点集合.

Step 3: 根据公式(23)计算增加分段后的信息损失函数值 l_k.

Step 4: 根据公式(24)计算增加分段前后的信息损失增益 ρ_k.

Step 5: 如果 $\rho_k>\rho_{\max}$, 则 $\rho_{\max}=\rho_k$.

Step 6: 如果 $k\ge k_{\max}$, 转至 Step 8; 否则, 令 $k=k+1$ 转至 Step 7.

Step 7: 遍历所有分段 $\mathbf{s}_r$ $(r=1,2,...,k)$ 在每个 $[b_{r-1},b_r)$ 中找到一个时刻 t 使得 $\psi(b_{r-1},t)+\psi(t,b_r)$ 最大, 计算并以该点为新分段点时目标函数值; 将使目标函数最大的时刻 t 作为新的分段点, 并将新的段点添加至分段点集合中, 更新段点标号使得 $b_0<b_1<...<b_{k+1}$, 转至 Step 3.

Step 8: 循环结束, 得到最佳分段点个数 k 以及分段点集合.

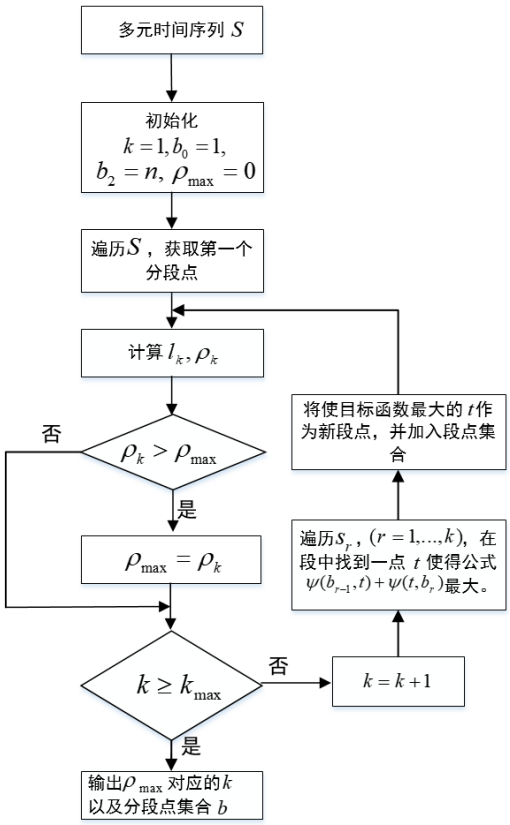

图 2 AGGS-MTS 算法流程图

2.4 计算复杂度分析

为便于评估算法的时间复杂度, 令多元时间序列的长度为表示为 n, 算法的最大分段数表示为 $k_{\max}$. AGGS-MTS 首先通过不断贪婪搜寻新的分段点, 假设平均每个段的长度为 l, 在分段点 $b_r\sim b_{r-1}$ 中遍历新增加一个分段点的过程中, 计算在时刻 t 处添加分段点而产生的左右分段的经验均值和协方差, 其时间复杂度是 $O(l^2)$. 求 $\psi(b_{r-1},t)+\psi(t,b_r)$ 的值, 其时间复杂度为 $O((b_r-b_{r-1})l^3)$. 对于整个长度为 n 的多元时间序列而言, 采用贪婪搜寻依次添加

$1,...,k_{\max}$ 个分段点,总时间复杂度为 $O(nk_{\max}(l^2+l^3))$. 其次, AGGS-MTS 利用信息增益确定最佳分段个数, 在分段的过程中计算每确定增加一个段点后的信息增益, 该过程的时间复杂度为 $O(n)$. 综上所述, 算法的总时间复杂度为 $O(k_{\max}n(l^2+l^3+1))$, 与时间序列长度 n 呈线性关系.

3 实验结果

在实验验证部分, 本文首先对多元时间序列分段准确性的评价指标加以介绍, 其次分别采用合成和真实的多元时间序列数据集来验证算法的性能, 最后将所提出算法用于真实多元时间序列数据集的异常检测. 实验将提出的算法与 SMTS_FD[10] 、SMTS_DP[11] 、FSTS_KPG[14] , IGTS[15]四种分段算法进行对比. 所有实验均是在 3.20GHz 处理器和 16.00GB 内存下运行的 Python 3.6 环境中执行.

3.1 评价指标

对于存在真实分段信息(Ground Truth)的数据集而言,为实现对于多元时间序列分段精度的评估, 较为常用的指标为 F_1 分数[21], 其公式如下所示,

$$F_1=\frac{2\times TP}{2\times TP+FN+FP} \tag{25}$$

假定数据集对应的真实分段点(Ground Truth)的位置集合表示为 $\{GT_i \mid i=1,...,h\}$, 待评估分段算法获得的实验分段点(Experimental Segmentation)的位置集合表示为 $\{b_r \mid r=1,...,k\}$, 则公式(25)中的真阳性 TP 代表 $\{GT_i \mid i=1,...,h\}$ 与 $\{b_r \mid r=1,...,k\}$ 中元素相等的次数, 假阳性 FP 代表 $\{b_r \mid r=1,...,k\}$ 中没有与之相等的真实分段点的元素个数. 假阴性 FN 代表 $\{GT_i \mid i=1,...,h\}$ 中没有与之相等的实验分段点的元素个数. F_1 分数越高, 分段结果越精确.

最近, 文献[23]指出, 直接将 F_1 分数作为评估指标将倾向于惩罚接近真实分段点的合理分割方案, 譬如对于真实分段点为 1000 的情况, F_1 分数只奖励实验分段点为 1000 的情况, 而惩罚实验分段点为 999 或 1001 的情况, 尽管它们的分段方案同样是合理的. 因此, 为弥补上述缺陷, 在数据集本身已经提供真实分段区间的情况下, 获得的实验分段点只要落在真实分段区间内, 则可标记为真阳性 TP, 对于仅仅给出真实分段点而未给出真实分段区间的数据集, 本文依据文献[24], 以每个真实分段点为中心, 并以 $0.025m$ 为半径定义真实分段区间, 其中 m 为整个多元时间序列的总长度, 落入该区间的实验分段点可同样被标记为真阳性 TP.

在特殊情况下, 当两种待评估算法获得的实验分段点都同时落在真实分段区间中, F_1 分数将无法继续评判两者的优劣. 为弥补上述缺陷, 文献[22]提出一种用于评估分段算法准确性的指标 MAE, 该指标通过计算实验分段点位置与其最邻近真实分段点位置的绝对值距离来评判结果的准确性, 其公式如下所示,

$$MAE=\frac{\sum_{i=1}^{h}|GT_i-b_{\tilde{r}}|}{m},\ \tilde{r}=\arg\min_{r\in(1,k)}|GT_i-b_r| \tag{26}$$

MAE 越低, 分段结果越精确. 需要注意的是, 该指标只适用于实验分段点总数与真实分段点总数相等的情况, 而 F_1 分数可以适用于实验分段点和真实分段点不相等的情况, 因此可与之形成互补.

3.2 合成数据集实验

考虑到人工数据集的分段点可以确定真实的分段位置, 本实验中采用了人工合成数据集来判断算法分段的准确性. 这里, 利用 1 阶向量自回归模型生成了一个 10 维时间序列数据集, 长度 T = 140, 所用的模型如下所示:

$$Z(t)=\begin{cases}\theta_0^{(1)}+\theta_1^{(1)}Z(t-1)+u^{(1)}(t), & 0<t\le 40;\\ \theta_0^{(2)}+\theta_1^{(2)}Z(t-1)+u^{(2)}(t), & 40<t\le 100;\\ \theta_0^{(1)}+\theta_1^{(1)}Z(t-1)+u^{(1)}(t), & 100<t\le 140;\end{cases} \tag{27}$$

其中 $Z(t)=[z_1(t),z_2(t),...,z_{10}(t)]',t=1,2,...,140;$ $u^{(1)}(t)$ 和 $u^{(2)}(t)$ 都服从均值为 0、协方差矩阵 $\Sigma=I$ 的多元正态分布. 模型的参数设置如下:

$$\theta_0^{(1)}=[3,3,3,3,3,-1,-1,-1,-1,-1]',$$
$$\theta_1^{(1)}=\begin{bmatrix}-0.9 & 0 & \cdots & 0\\ 0 & -0.9 & \cdots & 0\\ \vdots & \vdots & \ddots & \vdots\\ 0 & 0 & \cdots & -0.9\end{bmatrix} \tag{28}$$

$$\theta_0^{(2)}=[-1,-1,-1,-1,-1,5,5,5,5,5]',$$
$$\theta_1^{(2)}=\begin{bmatrix}0.6 & 0 & \cdots & 0\\ 0 & 0.6 & \cdots & 0\\ \vdots & \vdots & \ddots & \vdots\\ 0 & 0 & \cdots & 0.6\end{bmatrix} \tag{29}$$

对于该合成数据集, 可以知道其真实的分段点为 41, 100, 并将其真实分段区间的半径设定为时间序列总长的 0.025 倍. 首先, 实验利用 AGGS-MTS 算法对其进行分段处理. 图 3 为在不同段点数的情况下信息增益变化的情况, 当 $k=2$ 时信息增益发生了显著的变化. 计算前后两次获得的信息增益的信息增益变化率 R, 其结果显示在图 4 中. 因为信

息增益趋势急剧减小，在给定的 $k_{\max}$ 范围内最好的 k 是即时具有最大 R 的 k．因此，可以根据图 4，可以得知合成数据集最优的分段点的个数为 2.

为了评判提出算法分段的优越性，实验将不同算法运行到合成数据集上，图 5 为不同算法在合成数据集上的分段结果，其中只绘制了合成数据集中 10 个变量中 3 个变量的时间序列曲线，分别用 z_1, z_2, z_3 表示．图 5(a)中黑色虚线为真实分段点的位置，灰色矩形部分为真实分段区间，图 5(b)-(f)中黑色实线表示对应算法的实验分段点落在真实分段区间内的情况，红色实线表示对应算法的实验分段点落在真实分段区间外的情况．从图中可以看出 FSTS_KPG、SMTS_FD 和 SMTS_DP 算法在合成数据集上的分段效果并不理想，FSTS_KPG 和 SMTS_FD 的分段点的个数大于真实分段点的个数，SMTS_DP 分段点的位置与实际结果不重合，而 IGTS 和本文提出的算法 AGGS-MTS 所分割出来的结果与真实分段点的位置相吻合.

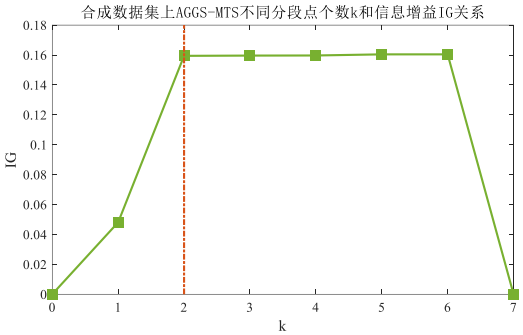

图 3 在合成数据集上不同分段点个数 k 和信息增益 IG 关系

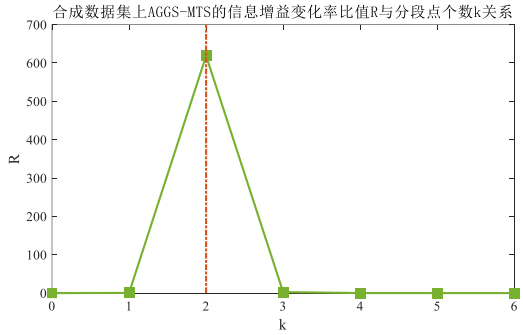

图 4 信息增益变化率比值 R 与分段点个数 k 关系

为了进一步评估提出算法的效率与准确度，实验统计了不同算法对合成数据集进行分段所用时间，F_1 分数以及 MAE，结果如表 2 所示．从表中的运行时间可以看出：本文提出的算法 AGGS-MTS 拥有最高的分段效率，这是因为在整个分段的过程中算法使用的是贪婪搜索策略，并且能够在搜索分段位置的同时确定最优分段数目，整个算法的复杂度与时间序列的长度呈线性关系; IGTS 算法与所提出算法都能够在搜寻分段位置的同时确定最优分段数目，但该算法基于动态规划，因此在分段效率上稍低于所提出算法 AGGS-MTS; SMTS_DP 和 SMTS_FD 不但采用动态规划的方法来进行分段位置的搜索，并且在分段之前还要对整个数据集进行聚类处理，算法的复杂度与时间序列的长度呈二次方关系，因此运行效率低下．从表中的 F_1 分数以及 MAE 可以看出，AGGS-MTS 以及 IGTS 都能够搜寻得到与真实分段点相同的分段结果, SMTS_DP 的分段结果与真实分段点稍有偏差, FSTS_KPG 以及 SMTS_FD 得到的分段点数量与真实分段点数量不相等，因此无法计算 MAE．综上所述，无论是分段效率还是分段准确度, AGGS-MTS 都拥有最好的性能.

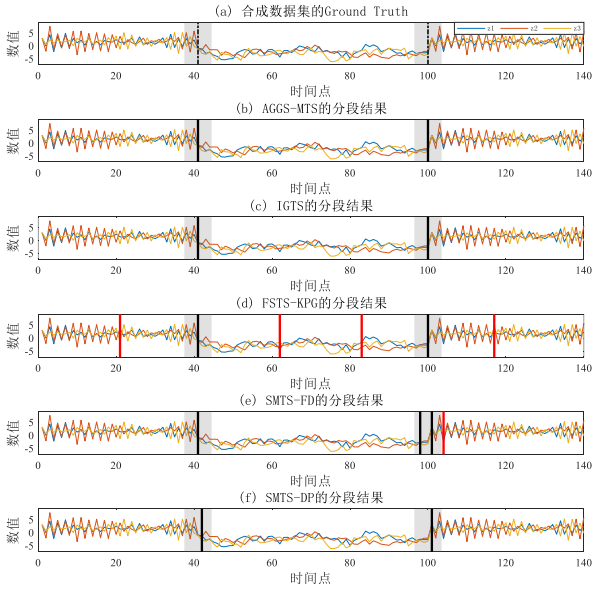

图 5 算法在合成数据集上的分段结果

表 2 不同算法在合成数据集上的分段结果

算法	运行时间(s)	分段位置	F_1	MAE
AGGS-MTS	**0. 070**	**41,100**	**1**	**0**
IGTS	0. 076	**41,100**	**1**	**0**
FSTS_KPG	0. 11	21,41,62,83,100,117	0.500	-
SMTS_FD	21. 86	41,98,101,104	0.857	-
SMTS_DP	45. 90	42, 101	**1**	0.014

3. 3 真实数据集实验

该部分使用两个真实多元时间序列数据集进行实验，包括 HY(Hydrometeorological)数据集[17] 和 CMU 人类动作捕捉数据集 Mocap[18].

3.3.1 HY 数据集的实验

HY 数据集是一个真实多元时间序列数据集，是美国阿雷西沃地区的水文气象数据，其中包含 WINDSPEED, DIR, GUSTS 三个变量．实验使用了

2014 年 1 月 3 日到 2014 年 1 月 5 日的数据，长度为 T=500. 首先利用 z-score 对数据集进行标准化处理后，再将其作为算法的输入，并对其进行分段.

图 6 为在 HY 数据集上不同分段点个数 k 和信息增益 IG 的关系，由图中可以看出当 $k=3$ 的时候 IG 的变化率有较大的改变，在 $k=3$ 之后，IG 在不断的缓慢变化. 通过对相邻两点的变化之比可以求得在 $k=3$ 的时候 R 为最大，其结果可以在图 7 中得知，所以该算法获得的最佳分段个数为 $k+1=4$.

由于对于真实环境的数据集没有办法准确的得知其真正的分段点的位置，但是可以通过时间序列的变化情况来判断其分段的好坏. 图 8 所示为 WINDSPEED, DIR, GUSTS 三个变量的时间序列变化曲线，从图 8(a)可以看出 AGGS-MTS 算法获得的分段的结果与时间序列的变化趋势相吻合，而其他算法在 HY 数集上的运行效果并不是很好. 因此对于真实数据集，AGGS-MTS 算法仍然能够较为准确的找到最佳的分段数.

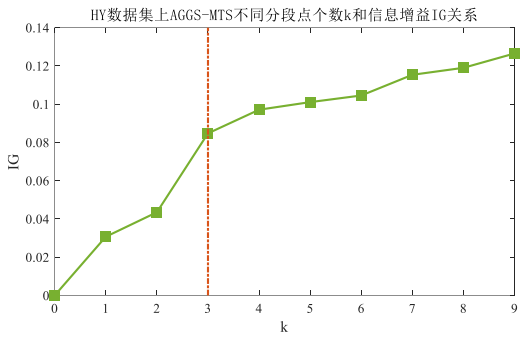

图 6 HY 数据集不同分段点个数 k 和信息增益 IG 关系

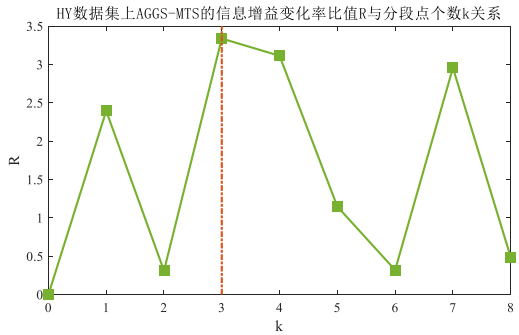

图 7 信息增益变化率比值 R 与分段点个数 k 的关系

为了进一步验证算法的分段性能，与在合成数据集上的实验相同，实验比较了不同算法在 HY 数据上运行的效率与获得最佳分段数的个数，实验结果如表 3 所示. 从表 3 可以看出，本文提出的 AGGS-MTS 算法的运行时间在所有算法中是最少的，特别是与 SMTS_DP 和 SMTS_FD 相比较，其运行效率是他们的将近 1000 倍.

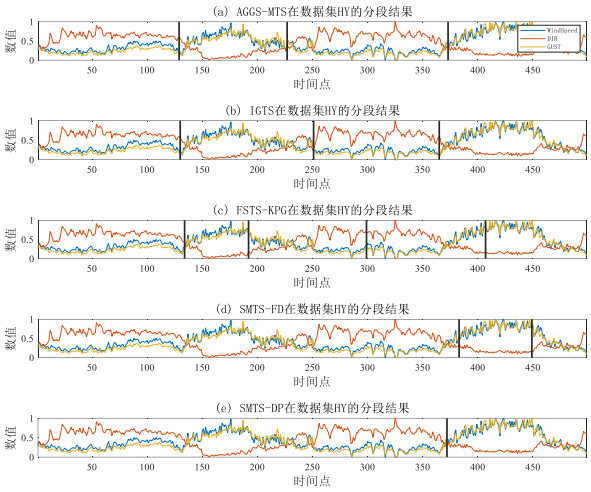

图 8 不同算法在 HY 数据集上的分段结果

表 3 不同算法对 HY 数据集的运行时间和最佳分段个数

算法	运行时间(s)	分段位置	分段数
AGGS-MTS	0. 34	129, 227, 373	4
IGTS	0. 72	130, 251, 365	4
FSTS_KPG	1. 22	134, 192, 299, 407	5
SMTS_FD	317. 35	383, 449	3
SMTS_DP	317. 30	372	2

从最佳分段个数来看，AGGS-MTS 和 IGTS 找到了相同的最佳分段个数，其他算法找到的最佳分段个数各不相同，再结合图 8(a)中时间序列的变化趋势，可以更加确定提出的算法能够找到更加合适的分段数，从而能够准确的对多元时间序列进行分段.

3.3.2 MoCap 数据集的实验

MoCap 数据集来自 CMU 动作捕捉数据库. 在这个数据集中，每个运动都被表示为数百帧的序列. 它由 64 维向量序列组成，实验中选择了其中四维(左右腿和手臂)的数据. 它由“走”、“蹲”、“跑”等几个连续的动作组成，每个动作又由左臂/右臂、左腿/右腿四个共同演化的序列组成，利用算法可以从这些运动序列中找到具体的运动(如“行走”和“奔跑”). 在本实验中选取了长度 T=2000 的时间序列数据集. 其真实最优分段点(Ground Truth)以及真实分段区间由文献[25]提供. 实验首先通过比较不同算法在该数据集上的分段的结果与真实分段点进行比较来判断算法的分段准确程度. 其次为了评价提出算法运行性能的好坏，实验又比较了不同算法在数据集上的运行时间.

首先让 AGGS-MTS 算法在数据集上运行. 选取的数据集的真实分段点个数为 2. 图 9 为在不同段点数的情况下信息增益变化的情况，从图中可以

看出，当 $k=2$ 时信息增益发生了显著的变化. 图 10 为信息增益变化率比值 R 与分段点个数 k 的关系，当 $k=2$ 时信息增益变化率的比值最大，所以，可以判断该数据集的最佳分段点的个数为 2，该结果与真实分段点的个数相同.

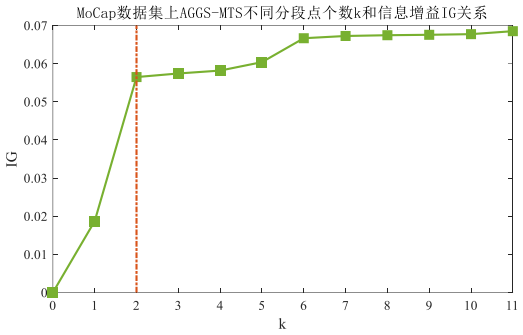

图 9 MoCap 数据集不同分段点个数 k 和信息增益 IG 关系

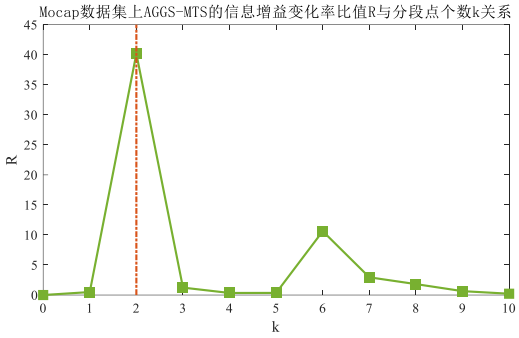

图 10 信息增益变化率比值 R 与分段点个数 k 的关系

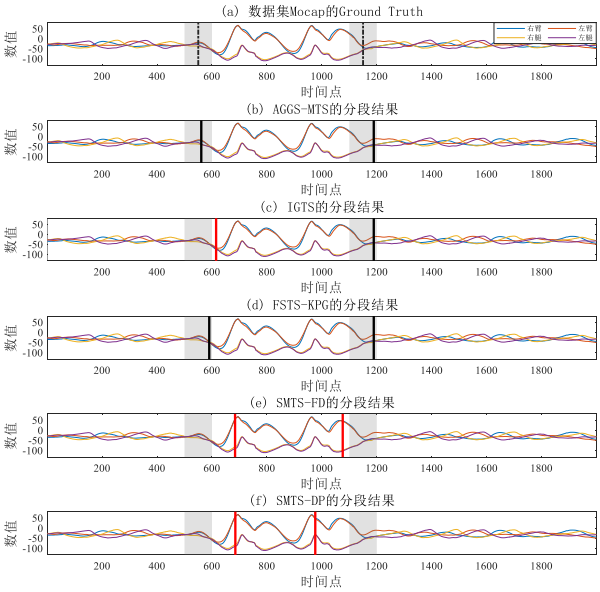

图 11 不同算法在 MoCap 数据集上的分段结果

其次，实验比较了 IGTS, SMTS_FD, SMTS_DP, FSTS_KPG 算法与提出的 AGGS-MTS 算法的性能. 图 11 为不同算法在数据集上的分段结果，图 11(a)中两条黑色虚线表示真实分段点(Ground Truth)，灰色阴影部分表示真实分段区间. 从图 11(b)-(f)可以看出, SMFTS_FD 和 SMFTS_DP 算法获得的分段点的位置全部位于给定的真实分段点范围之外，它们的分段准确性是最差的. IGTS 算法的第一个分段点的位置位于灰色区域外，获得的分段点的位置与真实分段点不符. AGGS-MTS 和 FSTS_KPG 算法所获得的分段点的位置都位于灰色区域范围内，这两种算法的分段结果较为准确.

表 4 为不同算法在 MoCap 数据集上的运行结果的汇总，其中包括算法的运行时间，分段位置，F_1 分数以及 MAE. 从表中可以看出 SMFTS_FD 和 SMFTS_DP 不管在运行效率还是分段的准确性上都是最差的. AGGS-MTS 和 FSTS_KPG 都能够得到相对准确的分段结果，但 FSTS_KPG 运行效率却低于 AGGS-MTS，并且 IGTS 算法的分段效率以及分段准确度都低于 AGGS-MTS. 综上所述，本文提出的算法拥有最优的分段性能.

表 4 不同算法对 MoCap 数据集的运行时间和最佳分段个数

算法	运行时间(s)	分段位置	F_1	MAE
AGGS-MTS	**1.67**	**561, 1189**	**1**	**0.025**
IGTS	1.85	615, 1185	0.500	0.050
FSTS_KPG	19.31	590, 1189	**1**	0.040
SMTS_FD	3040.56	684, 1076	0	0.104
SMTS_DP	4933.49	685, 976	0	0.154

3.4 AGGS-MTS 在异常检测任务中的应用

为了进一步验证 AGGS-MTS 算法的实际应用效果，本文将其用于异常检测任务. 所采用的实验数据包含信息检索，环境监测以及金融等领域的多元时间序列真实数据集，且均具有真实的异常点信息，具体信息见表 5. 其中，

表 5 多元时间序列异常检测真实数据集

数据集	时间戳总数	变量维数	所属领域
sweets	484	4	信息检索
flus	472	4	信息检索
occupancy	2275	5	环境监测
exchange	7588	7	金融

sweets[21]包含了用户使用 Google 搜索引擎在一段时间内查询与“甜点”话题相关的 4 种关键词的搜索量；flus[21]包含了用户使用 Google 搜索引擎在一段时间内查询与“流感”话题相关的 4 种关键词的搜索量；occupancy[26]记录了办公室内 5 种环境监测传感器在固定时间段内的数值；exchange[27]则记录了 1996 至 2016 年 7 个国家每日汇率的变化情况. 所有数据集在实验时均经过归一化处理. 利用 AGGS-MTS 对上述数据集分别进行分段，所得到的分段位置点（如图 12 中的黑色虚线所示）与上述数

据集所有真实异常点的位置完全一致.

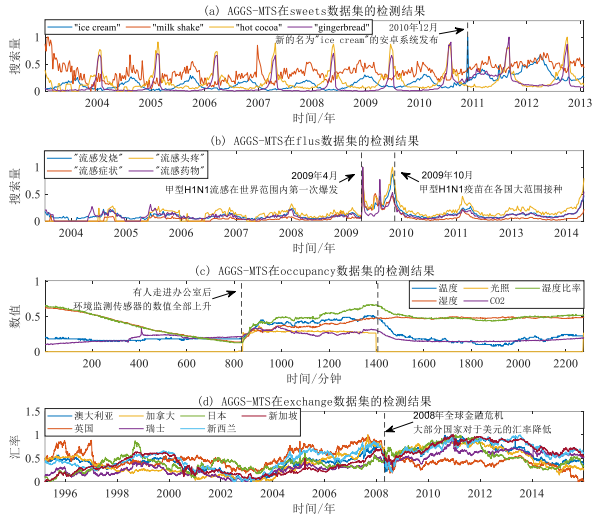

图 12 AGGS-MTS 在真实数据集上的异常检测结果

图 12(a)中的黑色虚线显示了 AGGS-MTS 对于 sweets 数据集异常点位置的检测结果. 用户在 Google 搜索引擎搜索与“甜点”话题相关的 4 种关键词(“ice cream”, “gingerbread”等)的搜索量在 2010 年以前具有明显的周期性, 然而在 2010 年 12 月前后“ice cream”的搜索量曲线出现了尖峰, 原因是由于安卓发布了名为“ice cream”的操作系统, 引起了歧义. 图 12(b)中的黑色虚线显示了 AGGS-MTS 对于 flus 数据集异常点位置的检测结果. 用户在 Google 搜索引擎搜索与“流感”话题相关的 4 种关键词(“流感发烧”, “流感症状”等), 在 2009 年 4 月和 2009 年 10 月发生了两大历史事件: 甲型 H1N1 流感在世界范围内的首次爆发以及疫苗的大范围接种, 致使上述 4 种关键词搜索量的趋势在上述两个时间点发生了明显的变化. 图 12(c)中的黑色虚线显示了 AGGS-MTS 对于 occupancy 数据集异常点位置的检测结果. 办公室内传感器持续监测室内的环境信息(温度, 光照等), 当有人走进办公室进行办公活动时, 所有传感器的数值都会呈现上升趋势, 当所有人离开办公室后, 传感器数值则会呈现一定幅度的回落趋势. 图 12(d)中的黑色虚线显示了 AGGS-MTS 对于 exchange 数据集异常点位置的检测结果, 当 2008 年全球金融危机爆发后, 大部分国家对于美元的汇率降低. 综上所述, 本文所提出的 AGGS-MTS 算法能够准确检测出上述多种领域真实的时序数据中存在的异常时间点.

4 结　论

为了解决现有分段算法不适用于多元时间序列的分段, 且效率低下问题, 本文提出了一种基于多元时间序列的自适应贪婪高斯分段算法 AGGS-MTS. 该算法采用包含不同均值与协方差的多元高斯分布对多元时序数据的各个分段进行拟合, 进而将分段问题转化为协方差正则化的最大似然估计问题进行求解. AGGS-MTS 通过贪婪策略搜寻最优的分段点组合, 并采用信息增益自适应的获取最优分段数, 以避免分段点位置确定和分段数目选择的孤立问题, 显著提高算法的运行效率. 实验部分分别以人工和真实数据集的分段任务以及真实多元时间序列的异常检测任务为例, 验证所提出算法的有效性和优越性. 结果表明, AGGS-MTS 在运行效率以及分段准确性方面均优于其他对比算法, 并且在异常检测领域具有较好的运用价值.

本文所提出的算法也存在一定的局限性. 首先, 当输入数据的分布情况与多元高斯分布差距较大时（譬如输入数据为重尾分布）, AGGS-MTS 输出的分段结果将有可能与真实分段信息存在较大偏差; 其次, 输入数据中的噪声点可能对 AGGS-MTS 产生不良影响, 最后, 当前的 AGGS-MTS 算法主要适用于离线分段场景. 在接下来的研究中, 我们将着重于增强 AGGS-MTS 对复杂分布以及噪声数据的处理能力, 并将其运用于流数据的分段场景.

参考文献 (References)

[1] Mello C E, Carvalho A S, Lyra A. Pedreira C E. Time series classification via divergence measures between probability density functions[J]. Pattern Recognition Letters. 2019, 125:42–48.

[2] Garcia-Vega S, León-Gómez E, Castellanos-Dominguez G. A time-series prediction framework using sequential learning algorithms and dimensionality reduction within a sparsification approach[J]. Pattern Recognition Letters, 2020,129:287–292.

[3] Bokde N, Beck M W, Álvarez F M, Kulat K. A novel imputation methodology for time series based on pattern sequence forecasting[J]. Pattern Recognition Letters, 2018, 116:88–96.

[4] Keogh E, Chu S, Hart D, Pazzani M. Segmenting time series: a survey and novel approach[J]. Data Mining in Time Series Databases, World Scientific. 2004:1–21.

[5] Hu Y, Guan P, Zhan P, et al. A Novel Segmentation and Representation Approach for Streaming Time Series[J]. IEEE Access, 2019: 184423-184437.

[6] GedikliA, Aksoy H, Unal N E. Segmentation algorithm for long time series analysis[J]. Stochastic Environmental Research and Risk Assessment. 2008,22(3):291-302.

[7] Pérez-Ortiz M, Durán-Rosal A M, Gutiérrez P A, Sanchez-Monedero J, Nikolaou A, Fernández-Navarro F, Hervás-Martínez C. On the use of evolutionary time series analysis for segmenting paleoclimate data[J].Neurocomputing,2019,326:3-14.

[8] Durán-Rosal A M, Gutiérrez-Peña P A, Martínez-Estudillo F J, Hervás–Martínez C. Time series representation by a novel hybrid segmentation algorithm[C]. International Conference on Hybrid Artificial Intelligence Systems, Springer,

2016:163–173.
[9] Nikolaou A, Gutiérrez P A, Durán A, Dicaire I, Fernández-Navarro F, Hervás-Martínez C. Detection of early warning signals in paleoclimate data using a genetic time series segmentation algorithm[J]. Climate Dynamics, 2015, 44 (7–8):1919–1933.
[10] Kehagias A, Nidelkou E, Petridis V. A dynamic programming segmentation procedure for hydrological and environmental time series[J]. Stochastic Environmental Research and Risk Assessment, 2006,20(1-2): 77-94.
[11] 王玲,徐培培,彭开香.基于因子模型和动态规划的多元时间序列分段方法[J].控制与决策,2020,35(01): 35-44.
(Wang L, Xu P P, Peng K X. Segmentation of multivariate time series with factor model and dynamic programming[J]. Control and Decision, 2020, 35(1): 35-44.)
[12] Seghouane A, Amari S. The AIC criterion and symmetrizing the Kullback-Leibler divergence[J]. IEEE Trans Neural Netw. 2007: 97–106.
[13] Hallac D, Nystrup P, Boyd S. Greedy Gaussian segmentation of multivariate time series [J]. Advances in Data Analysis and Classification, 2019, 13(3): 727-751.
[14] 王玲,朱慧.基于 KPCA 和 G-G 聚类的多元时间序列模糊分段[J].控制与决策,2021,36(01):115-124.
(Wang L, Zhu H. Fuzzy segmentation of multivariate time series with KPCA and G-G clustering[J]. Control and Decision, 2021, 36(1): 115-124.)
[15] Amin Sadri, Ren Y, Flora D. Salim. Information gain-based metric for recognizing transitions in human activities[J]. Pervasive and Mobile Computing, 2017, 38:92-109.
[16] Witten D, Tibshirani R. Covariance-regularized regression and classification for high dimensional problems[J]. Journal of the Royal Statistical Society: Series B (Statistical Methodology), 2009, 71(3):615–636.
[17] NOAA/NOS/CO-OPS. http://co-ops.nos.noaa.gov.
[18] http://mocap.cs.cmu.edu/
[19] Truong C, Oudre L, Vayatis N. Selective review of offline change point detection methods[J]. Signal Processing, 2020, 167: 107299.
[20] Hubert P. The segmentation procedure as a tool for discrete modeling of hydrometeorological regimes[J]. Stochastic Environmental Research and Risk Assessment, 2000, 14(4): 297-304.
[21] Matsubara Y, Sakurai Y, Faloutsos C. Autoplait: Automatic mining of co-evolving time sequences[C]//Proceedings of the 2014 ACM SIGMOD international conference on Management of data. 2014: 193-204.
[22] Gharghabi S, Ding Y, Yeh C C M, et al. Matrix profile VIII: domain agnostic online semantic segmentation at superhuman performance levels[C]//2017 IEEE international conference on data mining (ICDM). IEEE, 2017: 117-126.
[23] Lin J F S, Karg M, Kulić D. Movement primitive segmentation for human motion modeling: A framework for analysis[J]. IEEE Transactions on Human-Machine Systems, 2016, 46(3): 325-339.
[24] Muralidhar N, Tabassum A, Chen L, et al. Cut-n-reveal: Time series segmentations with explanations[J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2020, 11(5): 1-26.
[25] Barbič J, Safonova A, Pan J Y, et al. Segmenting motion capture data into distinct behaviors[C]//Proceedings of Graphics Interface 2004. 2004: 185-194.
[26] Candanedo L M, Feldheim V. Accurate occupancy detection of an office room from light, temperature, humidity and CO2 measurements using statistical learning models[J]. Energy and Buildings, 2016, 112: 28-39.
[27] Lai G, Chang W C, Yang Y, et al. Modeling long-and short-term temporal patterns with deep neural networks[C]//The 41st international ACM SIGIR conference on research & development in information retrieval. 2018: 95-104.